Analytics Engineering: Transformando Datos en Conocimiento

¿Qué es Analytics Engineering?

Analytics Engineering es una disciplina innovadora que **transforma datos crudos en datasets confiables, documentados y testeados** para su uso en Business Intelligence, Machine Learning y autoservicio de datos.

Actúa como el puente esencial entre **Data Engineering** (infraestructura y extracción/carga) y **Data Analytics** (insights y Business Intelligence).

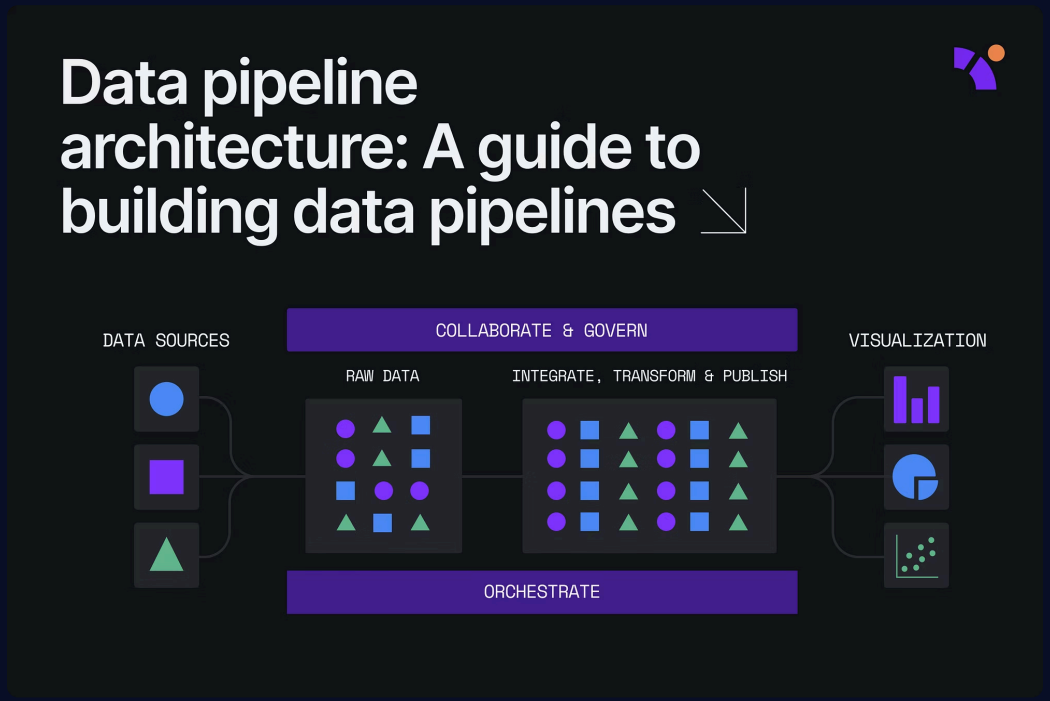

Su enfoque se centra en el **modelado de datos**, implementación de **tests automatizados**, creación de **documentación** comprehensiva, **control de versiones** y prácticas de **CI/CD**, constituyendo el crucial "T" del paradigma **ELT**.

El Rol del Analytics Engineer

Modelado Semántico

Diseña **modelos de datos** y **capas semánticas** coherentes que faciliten el entendimiento del negocio

Calidad de Datos

Garantiza la **calidad y frescura** de los datos mediante **tests automatizados** y sistemas de **observabilidad**

Documentación

Mantiene **documentación actualizada**, **lineage de datos** y **estándares organizacionales**

DevOps de Datos

Opera bajo **mejores prácticas de software** como pull requests, ramas y integración continua

ELT Moderno y el Lugar de dbt

El paradigma **ELT (Extract, Load, Transform)** representa un cambio fundamental: primero carga los datos en el data warehouse y luego los transforma aprovechando el cómputo elástico.

dbt (data build tool) ejecuta la transformación ("T") mediante **modelos SQL declarativos**, gestión de dependencias automática, tests integrados y documentación generada.

Sus beneficios incluyen **portabilidad** entre plataformas, **modularidad** en el código y **deployments repetibles** y auditables.

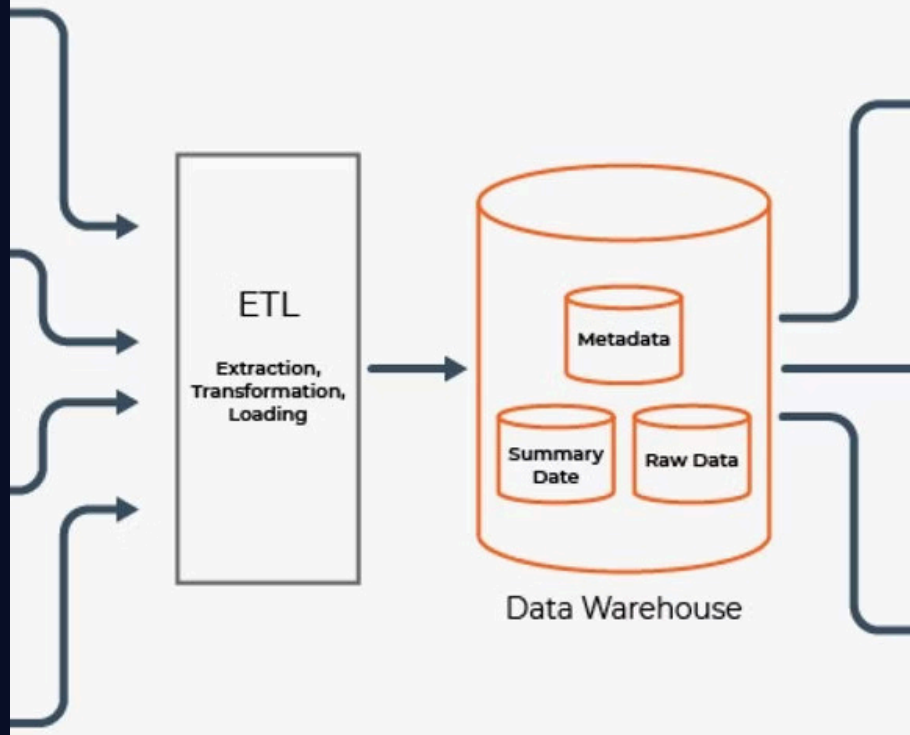

Fundamentos de dbt: Ecosistema Completo

Modelos

Selects SQL materializados con dependencias automáticas

Tests

Validaciones genéricas y singulares para calidad de datos

Sources & Exposures

Conexión con fuentes y activos downstream

Documentación

Catálogo automático con lineage y descripciones

Packages & Macros

Reutilización de código y lógica compartida

Seeds & Snapshots

Datos estáticos y versionado histórico SCD2

Arquitectura de Modelado en Capas

Raw/Staging

Datos crudos normalizados y tipados. Primera capa de limpieza y estandarización con granularidad máxima preservada.

Core (Negocio)

Lógica de negocio aplicada. Entidades centrales con reglas empresariales implementadas y granularidad de eventos.

Marts (Reporting)

Modelos optimizados para consumo. Agregaciones, métricas y vistas especializadas para BI y análisis.

Cada capa tiene **granularidad claramente definida** y **contratos de datos** explícitos que especifican tipos, unicidad y claves, protegidos por tests automáticos.

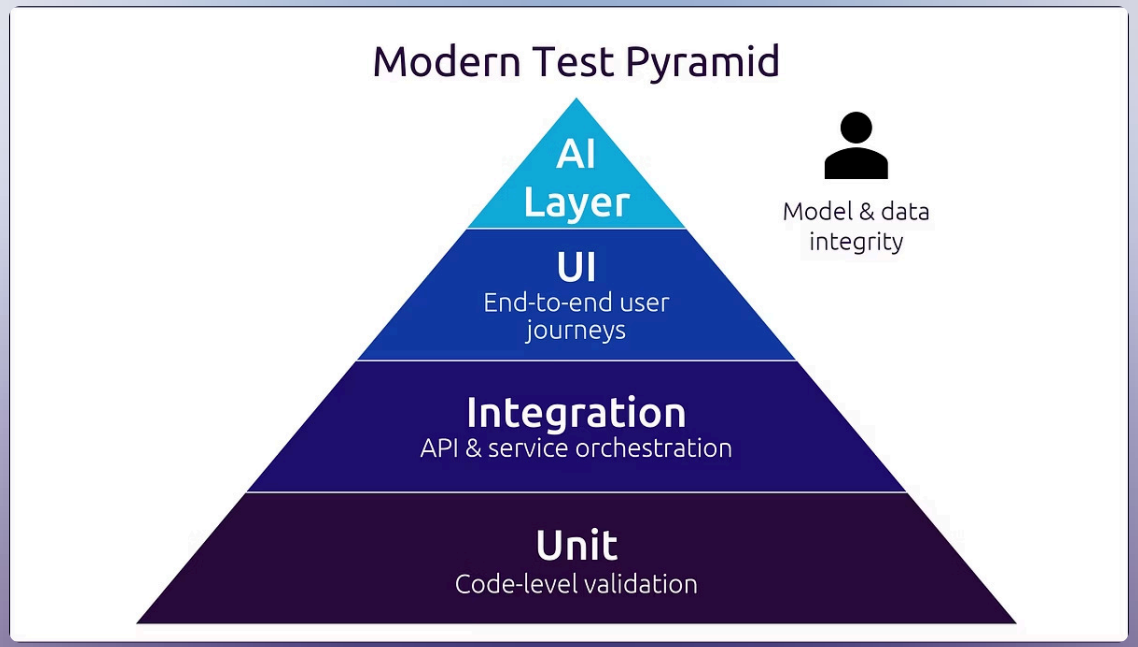

Testing en dbt: Garantizando Calidad

Tests Genéricos

Validaciones estándar como `not_null`, `unique`, `accepted_values` y `relationships` que se aplican a nivel de columna

Tests Singulares

Validaciones custom en SQL para reglas de negocio específicas y lógica compleja de validación

Fail Fast en CI

Los tests se ejecutan en CI/CD, bloqueando deploys si fallan y generando reportes accionables de errores

Source Freshness: SLA de Datos

Monitoreo Automático

Source Freshness supervisa si los datos se actualizaron dentro de los umbrales establecidos, comparando timestamps contra ventanas de tiempo definidas.

Requiere configurar el campo `loaded_at_field` y definir ventanas de alerta (**warn** y **error**) en minutos, horas o días según la criticidad de cada fuente.

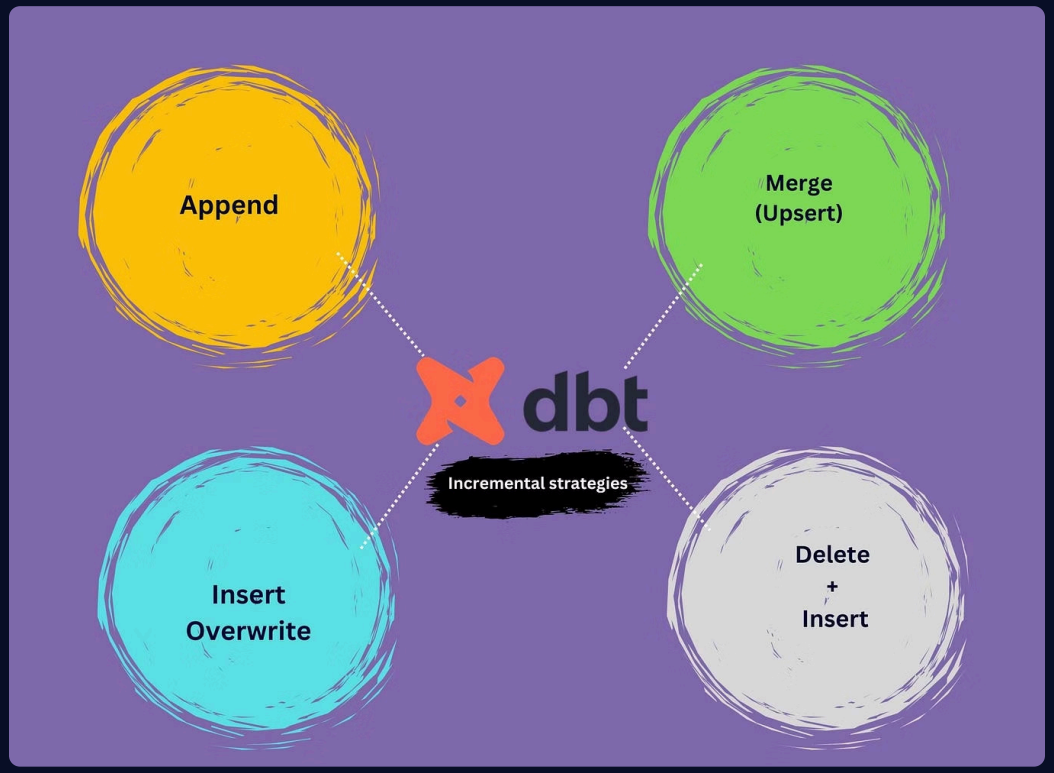

La interfaz proporciona visibilidad del **cumplimiento de SLA** en tiempo real, permitiendo identificar proactivamente retrasos en fuentes críticas antes de que impacten a los consumidores finales.

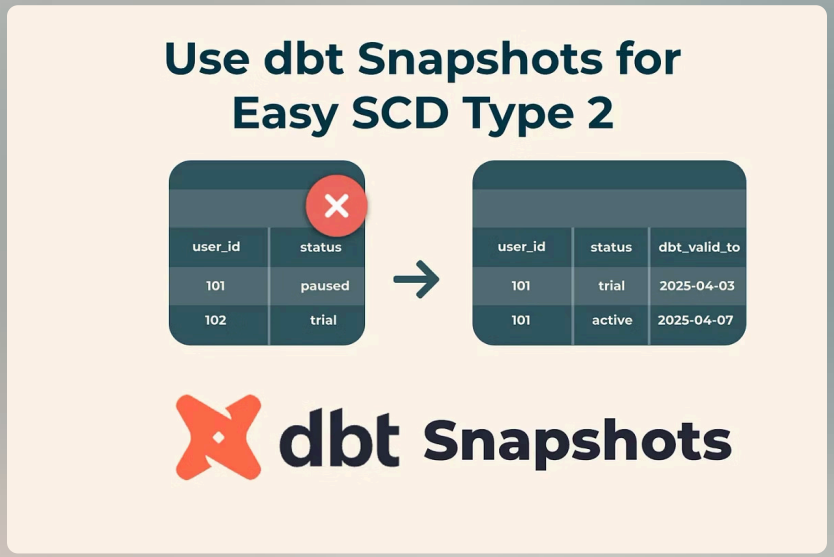

Snapshots: Capturando el Cambio Histórico

1. **Versión Original**
   Registro inicial con metadatos de validez temporal

2. **Cambio Detectado**
   Nueva versión creada, anterior marcada como histórica

3. **Análisis Temporal**
   Consultas "as of" para auditoría y análisis histórico

Los **Snapshots** implementan **Slowly Changing Dimensions Type 2 (SCD2)**, registrando automáticamente versiones de filas cuando cambian las columnas rastreadas. Esto habilita **auditoría completa** y análisis retrospectivos sin impactar los sistemas origen.

Documentación como Código

Catálogo Vivo

La documentación se mantiene "**como código**" en archivos YAML, generando automáticamente un **sitio web navegable** con descripciones a nivel de modelo, columna y fuente.

El **lineage interactivo** muestra dependencias y permite rastrear el flujo de datos desde origen hasta consumo, eliminando el "conocimiento tribal" y promoviendo el **autoservicio de datos**.

La generación automática mantiene la documentación sincronizada con los cambios del código, garantizando que siempre esté actualizada.

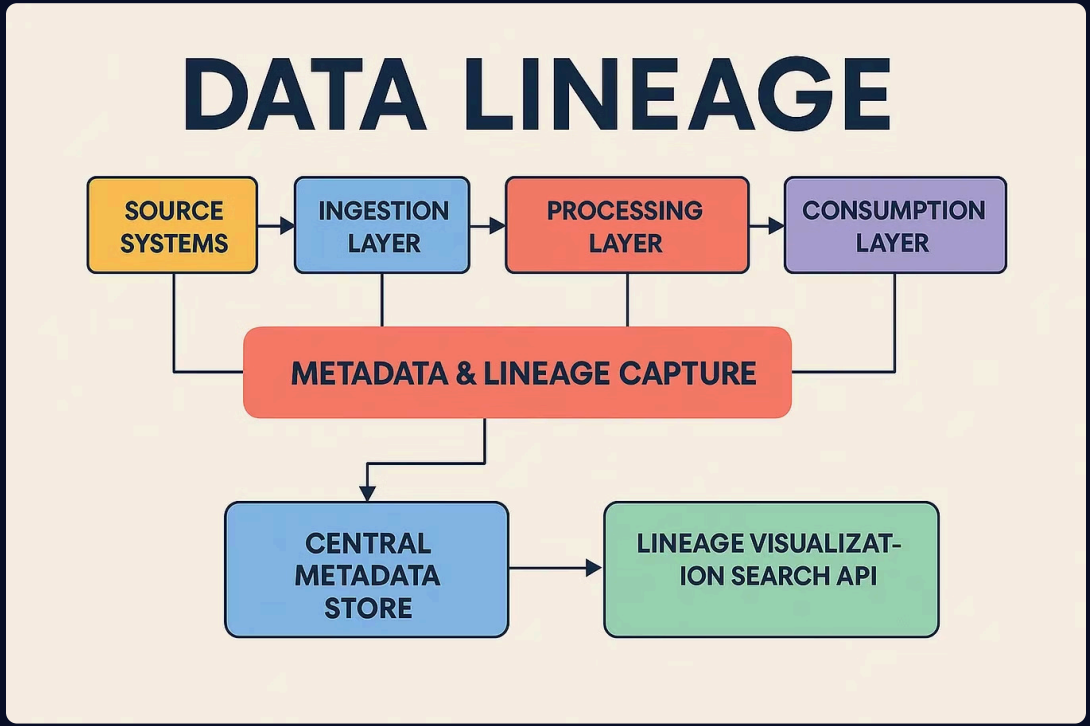

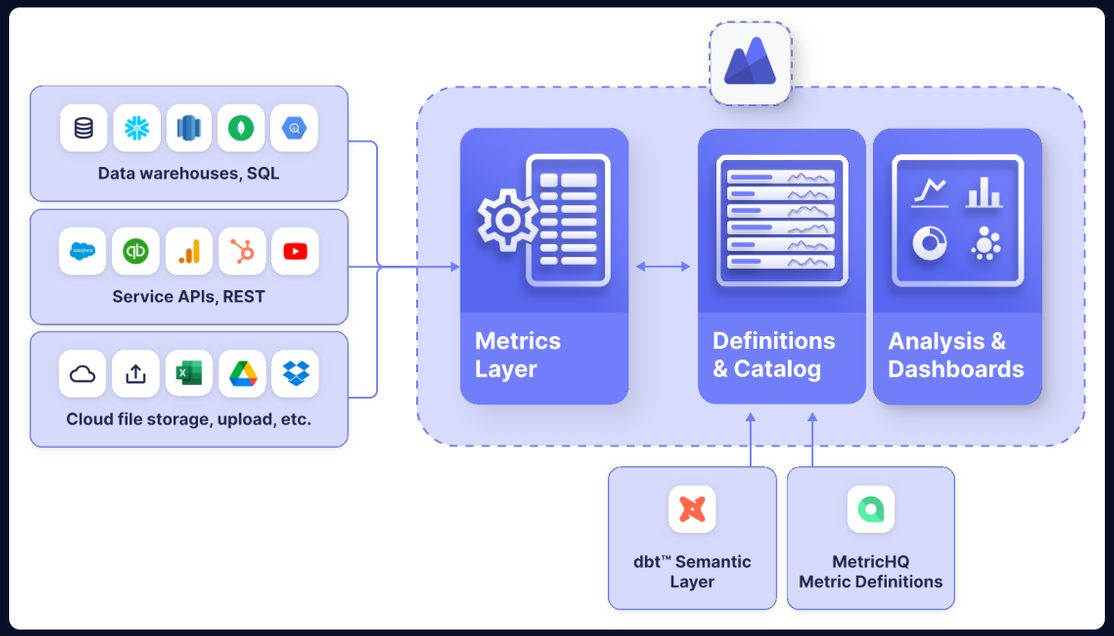

Semantic Layer: Métricas Consistentes

El **Semantic Layer con MetricFlow** permite **definir métricas una sola vez** especificando medidas, dimensiones, granularidad y entidades en un formato declarativo.

01

Definición Centralizada

Métricas definidas una vez con todas sus dimensiones y reglas de cálculo

02

Compilación Inteligente

MetricFlow genera SQL óptimo según el contexto de consulta solicitado

03

APIs Universales

Exposición consistente a herramientas de BI, aplicaciones y análisis

Esto elimina definiciones divergentes de KPIs y garantiza coherencia en toda la organización.

Packages y Macros: Reutilización Inteligente

Packages de Comunidad

Aprovecha paquetes desarrollados por la comunidad para funcionalidades comunes como utils, audit columns y transformaciones estándar

Macros Jinja

Plantillas reutilizables para patrones repetidos como generación de surrogate keys, pivoting dinámico y audit trails

Estandarización

Fomenta la **consistencia organizacional** y reduce la **deuda técnica** mediante código compartido y probado

Workflow de Desarrollo Colaborativo

Desarrollo Local

Los analistas trabajan en **entornos dev** aislados con ramas feature para nuevas funcionalidades

Revisión por Pares

Pull requests revisados enfocándose en **precisión semántica**, performance, cobertura de tests y documentación

Staging

Validación en entorno **staging** que replica producción antes del despliegue final

Producción

Deploy automatizado a **producción** tras pasar todas las validaciones y tests

Las **convenciones de naming**, organización por carpetas de dominio y asignación de owners facilitan la colaboración y mantenimiento.

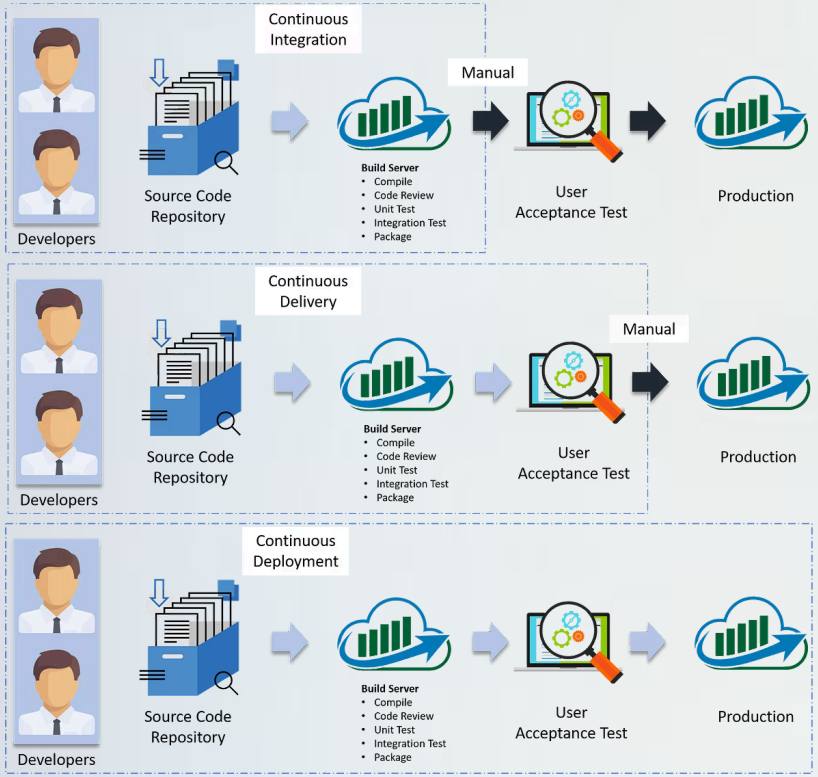

CI/CD para Analytics: Gate de Calidad

Automatización Total

El comando `dbt build` ejecuta en CI la secuencia completa: compilación, testing, snapshots y seeds **antes del merge**.

Actúa como **gate de calidad**: los pull requests **no se pueden mergear** si fallan tests, validaciones de frescura o cualquier otra validación configurada.

Herramientas Disponibles

- **dbt Cloud CI:** Solución nativa con integración completa
- **GitHub Actions:** Pipelines personalizables en GitHub
- **Runners personalizados:** Para entornos específicos

Orquestación y Gestión de Dependencias

Upstream EL

Procesos de extracción y carga de datos desde sistemas fuente

dbt build

Transformaciones, tests y materializaciones coordinadas

Notificaciones

Alertas y actualización de exposures downstream

dbt puede ejecutarse mediante su **scheduler propio** o integrarse con orquestadores como **Airflow o Dagster**. La clave es evitar el "ball of mud" separando pipelines por **dominio de negocio** y SLAs específicos.

Observabilidad y Health de Datos

99.5%

Uptime

Disponibilidad de fuentes críticas

15

Tests Fallando

Validaciones actualmente en rojo

45min

Tiempo Promedio

Duración típica del pipeline completo

El **panel de salud** proporciona visibilidad en tiempo real del estado del ecosistema de datos: frescura de fuentes, éxito de tests y fallas recientes.

Las **alertas proactivas** notifican sobre roturas y atrasos antes de que impacten a los usuarios finales. Las **métricas operativas** incluyen tiempo de ejecución, costo computacional y tamaño de modelos para optimización continua.

Performance Tuning en el Data Warehouse

Optimizaciones Fundamentales

- **Proyección selectiva:** Evitar SELECT * y especificar solo columnas necesarias
- **Filtrado temprano:** Aplicar WHERE clauses lo más pronto posible
- **Aprovechamiento de pruning:** Usar particionado y clustering nativos

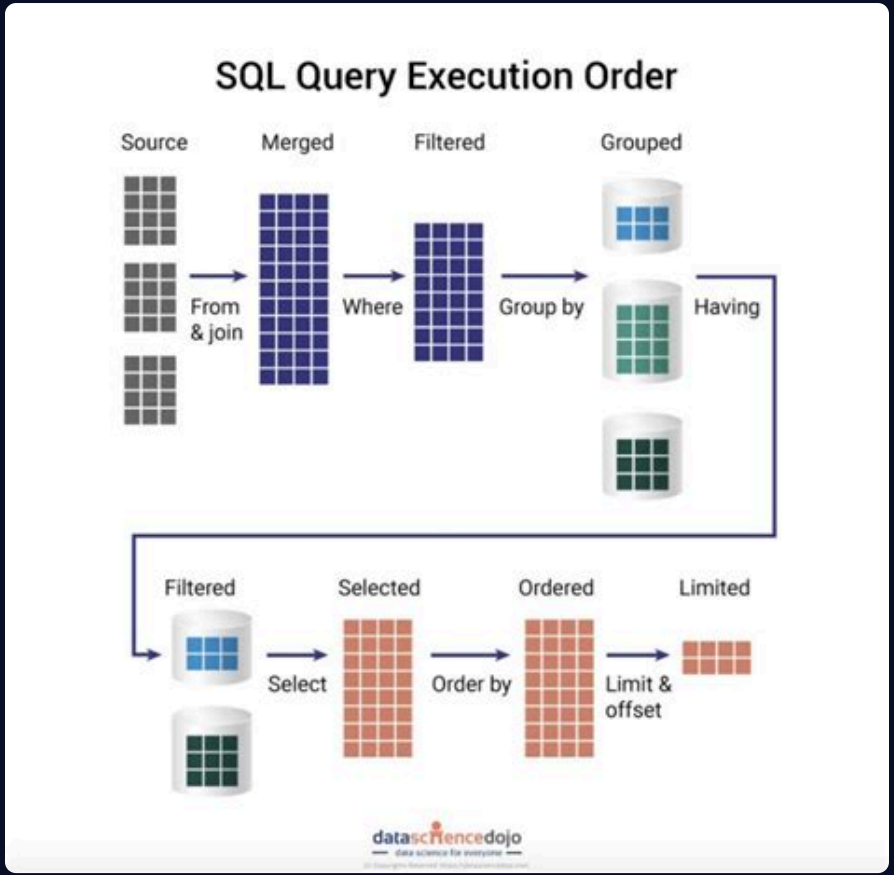

Ajustar las **materializaciones** según el patrón de cambio: usar **incremental** para tablas grandes con cambios frecuentes, **table** para datasets críticos que requieren baja latencia, y **view** para transformaciones ligeras.

Aprovechar **materialized views**, cachés y características específicas del motor del data warehouse para maximizar performance.

Data Quality Avanzada: Más Allá de dbt

Tests dbt Básicos

Validaciones fundamentales integradas en el pipeline de transformación

Frameworks Especializados

Great Expectations, Soda, Monte Carlo para checks más sofisticados

Monitoreo Continuo

SLAs/SLOs definidos con alertas automatizadas y escalamiento

Los Analytics Engineers integran múltiples herramientas de calidad, combinando la simplicidad de dbt con la sofisticación de frameworks especializados para crear un ecosistema robusto de **data quality**.

Gobierno, Seguridad y Acceso

Control de Acceso

RBAC y **mascaramiento** de datos sensibles implementados a nivel de data warehouse con auditoría completa

Trazabilidad

Lineage completo y logs de **auditoría** para cumplimiento regulatorio y investigación de incidentes

Contratos de Datos

Data contracts que especifican tipos y constraints, reforzados con tests para garantizar acuerdos con productores

Gestión de Activos

Exposures que identifican activos críticos, dashboards importantes y sus propietarios responsables

Mapa de Ruta del Analytics Engineer

Fase 1: Fundación

Staging confiable con tests básicos y documentación inicial. Establecer las bases sólidas del ecosistema de datos.

Fase 2: Madurez Operacional

Modelos **core de negocio**, CI/CD implementado, monitoreo de frescura y snapshots para auditoría histórica.

Fase 3: Excelencia Analítica

Semantic Layer con métricas consistentes, packages internos, SLOs definidos y observabilidad avanzada.

Entregables Clave del Analytics Engineer

- Modelos completamente testeados y documentados
- Documentación y lineage publicados y actualizados
- SLAs de fuentes monitoreados y alertas configuradas
- Métricas consistentes y centralizadas para toda la organización